Investigación: K-Nearest Neighbors (KNN)

Estudiante: Jorge Adalberto Zuñiga Oliva **Matrícula:** 82005 · **Grupo:** 512 **Materia:** Tópicos de Big Data **Fecha de entrega preparada:** 28 de octubre de 2026

1. Principio

KNN predice a partir de ejemplos cercanos a una consulta. En clasificación combina etiquetas; en regresión combina valores numéricos. Es un método no paramétrico: no presupone una recta para la relación entre entradas y respuesta. Al ajustar conserva datos y puede construir una estructura de búsqueda; el trabajo de localizar vecinos se realiza al consultar.

2. Procedimiento y ejemplo manual

Primero se define X, y y la partición de evaluación. Después se ajusta el preprocesamiento solo con entrenamiento, se eligen k y una distancia mediante validación, y se consultan los k vecinos. Con voto uniforme gana la clase más frecuente; con ponderación, los vecinos no aportan el mismo peso.

Considérense A=(0,0), A=(0,2), B=(3,0) y B=(3,2). Para la consulta (1,1), las dos distancias a A son sqrt(2) y las dos distancias a B son sqrt(5). Con k=3, dos vecinos son A y uno es B: el voto uniforme predice A. La distancia por sí misma no es una probabilidad de pertenencia.

3. Distancia y preparación

La distancia euclidiana es la raíz de la suma de diferencias al cuadrado. Manhattan suma valores absolutos; Minkowski generaliza ambas con un parámetro. La elección depende de las variables. Si una coordenada está en millones y otra en unidades, la primera puede dominar: se escala cuando eso corresponde a la pregunta. Si los atributos ya están en unidades comparables, escalar sigue siendo una decisión metodológica y no una regla universal automática.

Los faltantes requieren una estrategia previa. Categorías nominales necesitan representación adecuada; números de identificación no expresan semejanza. Un logaritmo puede ayudar con asimetría, pero cambia la geometría. Se debe aplicar la misma transformación a consulta y entrenamiento.

4. Elegir k sin mirar prueba

k pequeño produce decisiones locales sensibles al ruido. k grande suaviza y puede perder grupos minoritarios. Se comparan valores con validación cruzada y una métrica adecuada, manteniendo el conjunto de prueba reservado. La Pipeline vuelve a ajustar StandardScaler dentro de cada fold, evitando que las medias del fold de validación entren en el preprocesamiento.

5. Variantes, costo y dimensión

KNeighborsClassifier y KNeighborsRegressor usan voto y promedio, respectivamente. Se puede ponderar por distancia o definir un radio en vez de un número fijo. NearestNeighbors solo busca ejemplos similares y no necesita etiquetas. Búsquedas por fuerza bruta comparan la consulta con muchos registros; estructuras de árboles pueden acelerar ciertos casos.

En alta dimensión aumentan el costo y los problemas de representación de distancias. Variables irrelevantes pueden hacer menos útil la noción de cercanía. Reducir columnas exige validar de nuevo: no toda reducción preserva lo necesario para predecir. La memoria depende del entrenamiento conservado.

6. KNN y K-Means

Aspecto	KNN supervisado	K-Means
Uso de respuestas y	Sí	No
Significado de k	Número de vecinos de una consulta	Número de grupos
Resultado	Clase o valor de una consulta	Etiquetas y centroides
Evaluación	Métricas sobre respuestas reservadas	Separación, cohesión, estabilidad y utilidad

La consulta de vecinos del ejercicio mayorista utiliza NearestNeighbors. No debe describirse como clasificación KNN, porque no se predice una etiqueta conocida.

7. Implementación y resultados reproducibles

El archivo `ejemplo_knn.py` usa Iris incluido en scikit-learn. Reserva 30% para prueba, estratifica por especie y selecciona k entre 1, 3, 5, 7, 9 y 11 mediante cinco folds en el 70% restante. StandardScaler y KNN forman una Pipeline; se fija semilla 82005. Para reproducir:

```
python investigaciones/ejemplo_knn.py
```

En la ejecución, k=5; F1 macro medio de validación=0.9713. En prueba, accuracy=0.9556 y F1 macro=0.9554.

Filas de la matriz = clase real; columnas = predicción. Orden: setosa, versicolor, virginica.

Real / predicha	setosa	versicolor	virginica
setosa	15	0	0
versicolor	0	13	2
virginica	0	0	15

El conjunto de prueba tiene solo 45 ejemplos. Este resultado describe una partición de un dataset pequeño; no garantiza desempeño en otras flores, variables o poblaciones. Las clases confundidas se observan en la matriz y no deben ocultarse mostrando solo accuracy.

8. Conclusión

KNN es fácil de formular, pero una solución completa exige justificar representación, escala, distancia, k, costo y evaluación. Puede servir como línea base y para comparar observaciones similares. No convierte cercanía en causalidad ni reemplaza la comprobación en datos reservados.

Referencias

- scikit-learn: guía de vecinos cercanos.
- scikit-learn: KNeighborsClassifier.
- scikit-learn: GridSearchCV.
- scikit-learn: Iris y su referencia original.
- scikit-learn: matriz de confusión.