Práctica 1.1 — Probabilidad y Estadística

Análisis de la evolución poblacional mundial

Introducción

En esta primera práctica se trabajará con datos reales de población obtenidos de Our World in Data (OWID), cuya fuente original es United Nations, World Population Prospects (2024).

El propósito principal es familiarizarse con un conjunto de datos real y comprobar que el entorno de trabajo configurado para el curso funciona correctamente dentro de un Jupyter Notebook.

Durante la práctica se utilizarán Python, Pandas y NumPy para cargar, explorar y analizar estadísticamente los datos.

Objetivo

Utilizar un conjunto de datos real para comprobar el funcionamiento del entorno de análisis de datos y aplicar medidas estadísticas descriptivas básicas utilizando Pandas y NumPy.

Datos proporcionados

Los datos se encuentran organizados en:

data/ └── raw/ ├── annual_population_growth/ │ ├── annual-population-growth.csv │ ├── annual-population-growth.metadata.json │ └── annual-population-growth.README.md │ └── births_deaths/ ├── births-and-deaths-projected-to-2100.csv ├── births-and-deaths-projected-to-2100.metadata.json └── births-and-deaths-projected-to-2100.README.md

En esta práctica se utilizarán únicamente los datos históricos.

Los archivos .metadata.json y .README.md deberán conservarse porque contienen información sobre la fuente, las variables y el procesamiento de los datos.

Notebook

Todo el trabajo deberá realizarse en:

notebooks/

└── 01_evolucion_poblacional.ipynb

El notebook deberá seguir la misma estructura de actividades que esta práctica:

Práctica 1.1 — Probabilidad y Estadística

Análisis de la evolución poblacional mundial

Objetivo

Actividad 1 — Identificación de la fuente

Actividad 2 — Carga y exploración de datos

Actividad 3 — Estadística descriptiva

Actividad 4 — Comprobación del entorno

Resultados

Cada actividad deberá utilizar celdas Markdown para explicar brevemente lo realizado y celdas de código para ejecutar el análisis cuando corresponda.

Estructura del proyecto

El proyecto deberá mantener la estructura:

U1_1_probabilidad_estadistica/ │ ├── .venv/ │ ├── data/ │ └── raw/ │ ├── annual_population_growth/ │ └── births_deaths/ │ ├── notebooks/ │ └── 01_evolucion_poblacional.ipynb │ ├── src/ │ ├── .gitignore ├── README.md └── requirements.txt

La carpeta .venv/ no deberá incluirse en el repositorio.

Entrega

El estudiante deberá entregar su repositorio de GitHub con:

- README.md;
- requirements.txt;
- .gitignore;
- datos originales en data/raw/;
- notebook 01_evolucion_poblacional.ipynb.

El notebook deberá ejecutarse correctamente desde el inicio hasta el final.

Evidencia de aprendizaje

La práctica permitirá comprobar que el estudiante puede:

- trabajar con un conjunto de datos real;
- identificar y citar su fuente;
- utilizar un Jupyter Notebook;
- importar Pandas y NumPy;
- cargar un archivo CSV;
- explorar un DataFrame;
- calcular estadísticos descriptivos básicos;
- comprobar las versiones de las herramientas utilizadas;
- documentar su trabajo en un repositorio Git.

Actividad 1 — Identificación de la fuente

Propósito

Reconocer la procedencia del conjunto de datos antes de utilizarlo y documentar correctamente su fuente.

Instrucciones

Consulta los archivos:

annual-population-growth.README.md

annual-population-growth.metadata.json

Utiliza la información proporcionada para identificar la fuente de los datos.

En una celda Markdown del notebook documenta:

Cita de la fuente

Incluye en el notebook la referencia de la fuente utilizando la información de citación proporcionada por Our World in Data.

Los datos utilizados en esta práctica provienen de **Our World in Data (OWID)**.

La fuente original es **United Nations, World Population Prospects (2024)**.

Cita:

> UN, World Population Prospects (2024) – processed by Our World in Data. "Annual change in population – UN WPP" [dataset]. United Nations, "World Population Prospects"; United Nations, "World Population Prospects - Interim Update" [original data].

Preguntas

Responde brevemente:

1. ¿Quién produjo originalmente los datos?
2. ¿Qué organización los procesa para su utilización en Our World in Data?
3. ¿Qué representa la variable que analizarás?

Respuestas

1. ONU
2. Our World In data
3. El cambio poblacional con el paso de los años en cada país

UN, World Population Prospects (2024) – processed by Our World in Data

Actividad 2 — Carga y exploración de datos

Propósito

Comprobar que el entorno de Python, Pandas y Jupyter funciona correctamente y realizar una primera exploración del dataset.

2.1 Importar las bibliotecas

Importa:

import pandas as pd

import numpy as np

2.2 Cargar el archivo CSV

Utiliza pd.read_csv() para cargar:

data/raw/annual_population_growth/annual-population-growth.csv

2.3 Explorar el DataFrame

Utiliza Pandas para obtener:

- primeras filas; df.head()
- dimensiones; df.shape
- nombres de columnas; df.columns.tolist()
- tipos de datos; df.dtypes
- estadísticas descriptivas; df.describe()
- cantidad de valores faltantes; df.isnull().sum()
- cantidad de entidades; df["Entity"].nunique()

Preguntas

Responde brevemente:

1. ¿Cuántas filas y columnas tiene el dataset?
2. ¿Qué tipo de datos contiene la variable Year?
3. ¿Existen valores faltantes?
4. ¿Cuántas entidades diferentes contiene el dataset?

In [1]:
```
import pandas as pd
import numpy as np
```

In [6]:
```
df = pd.read_csv(r'C:\Users\Santiago\Desktop\Escuela\5to Semestre ISSC\BigData\U1_1

# Primeras Filas
df.head(5)
```

Out[6]:

	Entity	Code	Year	Annual change in population	Annual population change (Projected)
0	Afghanistan	AFG	1951	103163.0	NaN
1	Afghanistan	AFG	1952	108441.0	NaN
2	Afghanistan	AFG	1953	108919.0	NaN
3	Afghanistan	AFG	1954	111251.0	NaN
4	Afghanistan	AFG	1955	119027.0	NaN

In [7]:
```
print("Número de Filas y Columnas:")
df.shape
```

```
Número de Filas y Columnas:
```

Out[7]:
```
(38400, 5)
```

In [9]:
```
print("Nombres de Columnas")
df.columns.tolist()
```

```
Nombres de Columnas
```

Out[9]:
```
['Entity',
 'Code',
 'Year',
 'Annual change in population',
 'Annual population change (Projected)']
```

In [10]:
```
print("Tipos de Datos de Cada Columna")
df.dtypes
```

```
Tipos de Datos de Cada Columna
```

Out[10]:
```
Entity                                 str
Code                                   str
Year                                 int64
Annual change in population        float64
Annual population change (Projected)    float64
dtype: object
```

In [16]:
```
print("Resumen Estadístico:")
df.describe()
```

```
Resumen Estadístico:
```

Out[16]:

	Year	Annual change in population	Annual population change (Projected)
count	38400.000000	1.868800e+04	1.971200e+04
mean	2025.500000	2.063019e+06	8.375481e+05
std	43.300872	9.440859e+06	5.816745e+06
min	1951.000000	-3.315935e+06	-2.291035e+07
25%	1988.000000	1.781000e+03	-9.742750e+03
50%	2025.500000	4.689800e+04	9.350000e+01
75%	2063.000000	3.021128e+05	1.411160e+05
max	2100.000000	9.337137e+07	7.206736e+07

In [15]:
```
print("Valores Nulos por Columna:")
df.isnull().sum()
```

```
Valores Nulos por Columna:
```

Out[15]:
```
Entity                                0
Code                               1200
Year                                  0
Annual change in population       19712
Annual population change (Projected)    18688
dtype: int64
```

In [37]:
```
print("Número de Entidades Únicas:")
df["Entity"].nunique()
```

```
Número de Entidades Únicas:
```

Out[37]:
```
256
```

Preguntas

Responde brevemente:

1. ¿Cuántas filas y columnas tiene el dataset? 38400 filas y 5 columnas
2. ¿Qué tipo de datos contiene la variable Year? int64
3. ¿Existen valores faltantes? si, hay variass columnas con campos vacíos
4. ¿Cuántas entidades diferentes contiene el dataset? 256

Actividad 3 — Estadística descriptiva

Propósito

Aplicar medidas estadísticas básicas a una variable poblacional.

Instrucciones

Selecciona un año del periodo histórico y filtra los datos correspondientes.

Sobre la variable de cambio anual de población, calcula:

- media;
- mediana;
- varianza;
- desviación estándar;
- mínimo;
- máximo.

Utiliza Pandas y NumPy cuando corresponda.

Puedes utilizar operaciones como:

df.mean()

df.median()

df.var()

df.std()

df.min()

df.max()

Preguntas

Responde brevemente:

1. ¿Cuál es el valor de la media?
2. ¿Cuál es el valor de la mediana?
3. ¿Cuál es el valor de la desviación estándar?
4. ¿Qué entidad presenta el valor mínimo y cuál el máximo?

In [30]:
```
print("Media:")
df['Annual change in population'].mean()
```

```
Media:
```

Out[30]: np.float64(2063019.2590967466)

In [31]:
```
print("Mediana:")
df['Annual change in population'].median()
```

```
Mediana:
```

Out[31]: np.float64(46898.0)

In [32]:
```
print("Varianza:")
df['Annual change in population'].var()
```

```
Varianza:
```

Out[32]: np.float64(89129827668962.33)

In [33]:
```
print("Desviación Estándar:")
df['Annual change in population'].std()
```

```
Desviación Estándar:
```

Out[33]: np.float64(9440859.477238411)

In [34]:
```
print("Mínimo:")
df['Annual change in population'].min()
```

```
Mínimo:
```

Out[34]: np.float64(-3315935.0)

In [35]:
```
print("Máximo:")
df['Annual change in population'].max()
```

```
Máximo:
```

Out[35]: np.float64(93371370.0)

Preguntas

Responde brevemente:

1. ¿Cuál es el valor de la media? 2063019.2590967466
2. ¿Cuál es el valor de la mediana? 46898
3. ¿Cuál es el valor de la desviación estándar? 9440859.477238411
4. ¿Qué entidad presenta el valor mínimo y cuál el máximo? min: -3315935 , max: 93371370

In [39]:
```
print("Elegir filtro por año")
df_2020 = df[df['Year'] == 2020]
df_2020.head(5)
```

```
Elegir filtro por año
```

Out[39]:

	Entity	Code	Year	Annual change in population	Annual population change (Projected)
69	Afghanistan	AFG	2020	1212852.0	NaN
219	Africa (UN)	UN_AFR	2020	32815675.0	NaN
369	Albania	ALB	2020	-13061.0	NaN
519	Algeria	DZA	2020	747543.0	NaN
669	American Samoa	ASM	2020	-451.0	NaN

In [40]:
```
print("Filtro para mostrar solo las columnas que quiero")
df_2020_ext_col1 = df_2020[['Entity', 'Year']]
df_2020_ext_col1.head(5)
```

```
Filtro para mostrar solo las columnas que quiero
```

Out[40]:

	Entity	Year
69	Afghanistan	2020
219	Africa (UN)	2020
369	Albania	2020
519	Algeria	2020
669	American Samoa	2020

In [41]:
```
print("Filtrar datos utilizando filtros múltiples y condiciones")

print("Annual Change in Population between 1983 and 2021 in Mexico")


df_ext_MX_83_21 = df[(df['Entity'] == 'Mexico') & (df['Year'] >= 1983) & (df['Year'
df_ext_MX_83_21.head(5)
```

```
Filtrar datos utilizando filtros múltiples y condiciones
Annual Change in Population between 1983 and 2021 in Mexico
```

Out[41]:

	Entity	Code	Year	Annual change in population	Annual population change (Projected)
22232	Mexico	MEX	1983	1537980.0	NaN
22233	Mexico	MEX	1984	1535610.0	NaN
22234	Mexico	MEX	1985	1536567.0	NaN
22235	Mexico	MEX	1986	1542223.0	NaN
22236	Mexico	MEX	1987	1551014.0	NaN

In [49]:
```
#df_min_population = df[df["Entity", "Annual change in population"] == df['Annual c
df_max_population = df[df['Annual change in population'] == df['Annual change in po
```

```
df_min_population = df[df['Annual change in population'] == df['Annual change in po

df_min_country = df_min_population['Entity']
df_max_country = df_max_population['Entity']

print(df_min_country)
print(df_max_country)
```

```
35772    Ukraine
Name: Entity, dtype: str
37839    World
Name: Entity, dtype: str
```

Actividad 4 — Comprobación del entorno

Propósito

Comprobar que el notebook está utilizando correctamente las herramientas configuradas para la práctica.

Instrucciones

En una celda del notebook muestra las versiones de:

- Python;
- Pandas;
- NumPy.

Utiliza:

import sys

print("Python:", sys.version)

print("Pandas:", pd.**version**)

print("NumPy:", np.**version**)

Verifica que las versiones corresponden al entorno virtual utilizado para la práctica.

Finalmente, ejecuta nuevamente todas las celdas del notebook desde el inicio para comprobar que el análisis puede reproducirse correctamente.

Resultados

El notebook deberá terminar mostrando:

- información básica de la fuente;
- la cita de la fuente;
- el DataFrame cargado correctamente;
- información sobre su estructura;
- resultados de los estadísticos calculados;
- versiones de Python, Pandas y NumPy.

No es necesario realizar:

- gráficas;
- conclusiones;
- análisis de proyecciones;
- análisis temporal.

Estos temas serán incorporados en prácticas posteriores.

In [51]:
```
import sys

print("Python" , sys.version)
print("Pandas" , pd.__version__)
print("Numpy" , np.__version__)
```

```
Python 3.14.7 (tags/v3.14.7:823f032, Aug  5 2026, 10:51:32) [MSC v.1944 64 bit (AMD6
4)]
Pandas 3.0.5
Numpy 2.5.2
```