Resumen de Práctica: Comparación de Modelos de Regresión

Objetivo de la Práctica

El objetivo principal fue construir y comparar diferentes modelos de aprendizaje supervisado (Machine Learning) para proyectar la cantidad de nacimientos y defunciones de Japón hacia el futuro (año 2100). Se utilizaron datos demográficos históricos de Our World In Data (OWID), donde la variable predictora fue el 'Año' y la variable objetivo fue la cantidad de nacimientos o defunciones.

1. Regresión Lineal

¿Qué se hizo? Se entrenó un modelo LinearRegression utilizando los datos históricos. Este modelo asume que existe una relación constante (una línea recta) entre el avance de los años y el número de eventos demográficos.

Resultados: Al graficar los resultados, se observó que la recta de regresión lineal no puede capturar las variaciones reales (picos y valles) de los datos de Japón. En las proyecciones a largo plazo (año 2100), el modelo tiende a subestimar drásticamente los datos, sugiriendo valores que pueden llegar a ser negativos, lo cual carece de sentido biológico y demográfico.

2. Regresión Polinomial

¿Qué se hizo? Se aplicó una transformación PolynomialFeatures de grado 2 a la variable predictora antes de aplicar regresión lineal. Esto permitió que el modelo trazara una curva en lugar de una recta.

Resultados: El ajuste a los datos históricos fue visualmente excelente, logrando capturar la curva en forma de 'montaña' de los nacimientos. Sin embargo, su principal desventaja se hizo evidente en la extrapolación hacia el futuro: la función parabólica cae bruscamente hacia el infinito negativo. En el año 2100, las predicciones resultaron en valores absurdos (millones en números negativos), demostrando que extrapolar polinomios a largo plazo es muy peligroso.

3. Random Forest Regressor

¿Qué se hizo? Se entrenó un algoritmo basado en múltiples árboles de decisión (ensamblaje). Estos modelos fragmentan los datos y calculan promedios sobre segmentos históricos.

Resultados: En los datos de entrenamiento (históricos), el modelo sobreajustó (overfitting) la serie trazando una línea casi idéntica a los datos reales. El problema surgió en la proyección después de 2023: la curva se volvió completamente plana. Random Forest no es capaz de predecir valores fuera del rango numérico con el que fue entrenado, por lo que su capacidad de pronosticar tendencias futuras a largo plazo fue nula.

Conclusión General

La práctica evidenció los riesgos de utilizar algoritmos de regresión matemáticos puros para predecir series de tiempo complejas a largo plazo (extrapolación). Cada modelo mostró limitaciones graves al proyectar hacia el año 2100. Para realizar proyecciones demográficas útiles, es necesario usar sistemas especializados como los de la ONU, que contemplan la estructura por edades, fertilidad, y aspectos sociales, y no solo ajustar funciones estadísticas al pasado.